



DATA
MANAGEMENT

DATA MANAGEMENT

A GENERAL VIEW

1

Teaching team

2

Course goals and
organization

3

Exam rules

4

Experience from the
past

TEACHING TEAM


- Data management
 - Prof. Andrea Maurino (lead professor) andrea.maurino@unimib.it

SCHEDULE


- See the calendar
- November 25 and 26 there will be recorded lectures
- In-presence and registered lessons

COURSE ORGANIZATION


- Main topic: DATA LIFE CYCLE
 - Data science not only BIG DATA



WHAT A REAL DATA SCIENTIST DO?




THE TRUTH....



What data scientists spend the most time doing

- Building training sets: 3%
- Cleaning and organizing data: 60%
- Collecting data sets: 19%
- Mining data for patterns: 9%
- Refining algorithms: 4%
- Other: 5%



What's the least enjoyable part of data science?

- Building training sets: 10%
- Cleaning and organizing data: 57%
- Collecting data sets: 21%
- Mining data for patterns: 3%
- Refining algorithms: 4%
- Other: 5%

DATA MANAGEMENT TEXTBOOKS

- Davy Cielen, Arno D. B. Meysman, and Mohamed Ali. Introducing Data Science, manning, 2016
- Harrison Next Generation Databases, Apress, 2015.
- In Italian
 - Rezzani, Big Data Analytics, APOGEO 2017
 - Chapter of book “dalle basi di dati alla scienze dei dati” (in Italian)

EXAM

- The final grade of the course consists of the results of the two modules
 - 50% each
- For the data management module, the exam consists of two parts:
 - Written exam (open questions)
 - Minimum grade 15/30
 - Project
- Notice that
 - Both are valid for one academic year
 - It is possible to split the two parts of the exam

MINIMUM REQUIREMENTS FOR THE PROJECT

- The project must be approved by the teacher
 - From 1 to max 3 students
- At least two different data sources must be collected with one of the following techniques
 - API
 - Web scraper
 - Download dataset or query (only if previous constraints are satisfied)
- Datasets must be integrated and/or enriched
- Datasets must be stored in a (no)SQL database
- Exploratory data analysis must be realized (single source or integrated ones)
- Data quality assessment and improvement must be performed
 - Select at least two quality dimensions
- If the project is not sufficient or you refuse the final grade, you must present a new project

SPOTYWHY



CRONACA

Come si “costruisce” l’artista musicale di successo? Chiedilo a Spotify


Data Science Università Bicocca | 28 giugno 2018



Quello che state per leggere è il primo di una serie di articoli in collaborazione tra gli studenti di Data Science dell'Università di Milano-Bicocca e noi di Info Data con l'obiettivo di formare gli studenti di data science sull'applicazione dell'analisi dei dati al giornalismo. Ecco cosa abbiamo capito analizzando i dati di un anno di ascolti – il 2017 – su Spotify, il servizio musicale che offre lo streaming on demand di più di 30 milioni di brani delle principali case discografiche internazionali.

Il 2017 è stato l'anno di Ed Sheeran e Despacito, gli ascoltatori di tutto il mondo hanno decretato il loro trionfo in cima alle classifiche mondiali con miliardi di views tra Youtube e Spotify. Ma quali caratteristiche li hanno condotti in vetta? Quali sono i dettagli che più influiscono nel destino di un pezzo, distinguendo le Hit di successo dai flop musicali? Un'attenta analisi degli ascolti in scala mondiale ha fatto emergere i punti chiave che contraddistinguono i brani delle canzoni emergenti sui gradini più alti del podio.

Classifica delle canzoni più ascoltate del 2017



Classifica Spotify 2017
Source: Spotify Charts, Wikipedia


Quali sono le canzoni più ascoltate del 2017 su Spotify?

SOCIAL LISTENING



AUGUST

- What, when and where italian use tweets in August



VIRTUAL LAB

- Microsoft azure
 - One virtual pc
 - A low-cost pc for collecting data