

STIMA

REGRESSIONE LINEARE

Fabio Stella


Professore Associato

c/o Dipartimento di Informatica, Sistemistica e Comunicazione

Università degli Studi di Milano Bicocca



Parte dei contenuti della presente lezione sono tratti dai testi elencati di seguito.



Carlo Vercellis (2006). *Business intelligence: modelli matematici e sistemi per le decisioni*, McGraw-Hill.

Eventuali errori di battitura o di interpretazione degli argomenti presentati sono da imputare solo ed esclusivamente all'autore della presente lezione.

Si propongono di identificare un legame funzionale tra un *attributo target* e un insieme di *attributi esplicativi*.

Consentono di scoprire il legame esistente tra le variabili esplicative e la variabile target e allo stesso tempo consentono di effettuare previsioni circa i valori assunti dalla variabile target per determinati valori fissati delle variabili esplicative.

Supponiamo di disporre di un dataset contenente " $n+1$ " attributi, " n " attributi candidati ad essere esplicativi ed un attributo target, e " m " osservazioni.

Il *target* viene spesso chiamato *variabile di risposta*, *output*, *variabile dipendente*, mentre gli *attributi esplicativi* vengono di norma menzionati come *variabili indipendenti* o anche *predittori*.

La realizzazione delle variabili indipendenti per ogni osservazione " i " viene indicata con x_i , mentre la realizzazione dell'attributo target viene indicata con y_i .

Inoltre, indichiamo tramite $\mathbf{X}$ la matrice, di dimensioni $[m \times n]$, delle realizzazioni delle “n” variabili indipendenti e con $\mathbf{y}=(y_1, \dots, y_m)$. Infine, indichiamo con Y la variabile aleatoria associata alla variabile target e con x^j la variabile esplicativa *j-sima*.

Nei modelli di stima si ipotizza l’esistenza di una funzione

$$f : R^n \rightarrow R$$

che esprime il legame tra la variabile dipendente Y e le “n” variabili indipendenti x^j , si ipotizza che

$$Y = f(X^1, \dots, X^n)$$

in verità si ipotizza che esista l’aggiunta di un termine di errore “ ε ” con determinate caratteristiche che introdurremo più avanti

$$Y = f(X^1, \dots, X^n) + \varepsilon$$

I modelli di regressione lineare rappresentano la classe più nota di modelli di stima e si basano su uno spazio delle ipotesi costituito dalle sole funzioni lineari. Conseguentemente, il legame funzionale riportato in precedenza si riduce a:

$$f(X^1, \dots, X^n) = w^1 X^1 + \dots + w^n X^n + b = \sum_{j=1}^n w^j X^j + b$$

Nel caso in cui sia presente una sola variabile indipendente "**X**" (**n=1**), il modello viene detto *modello di regressione lineare semplice* e si riduce alla seguente relazione:

$$f(X) = wX + b$$

Tale modello è particolarmente importante, non tanto per il suo effettivo utilizzo in ambito reale, ma in quanto consente di presentare le principali caratteristiche dei modelli di regressione lineare con un numero generico di variabili candidate esplicative che presenteremo ed utilizzeremo più avanti.

Consideriamo un database che contenga informazioni circa i volumi di vendita di grossi outlet informatici

Sales:	volume di vendita
Titles:	numero di differenti articoli software in esposizione
Footage:	dimensioni dell'esposizione
IBMbase:	numero di clienti IBM
Appbase:	numero di clienti Apple

Supponiamo di voler modellare il valore del volume di vendita **Sales** in funzione del numero di differenti articoli software in esposizione **Titles**. Utilizzeremo il seguente modello di regressione lineare semplice


$$Y = wX + b + \varepsilon \longleftrightarrow \text{Sales} = w\text{Titles} + b + \varepsilon$$

dove " ε " nota come scarto o errore o residuo è

$$\varepsilon = Y - f(X)$$

Regressione Lineare Semplice

5



Il legame ricercato è di natura approssimata e pertanto è fondamentale stabilire un criterio mediante il quale identificare tra tutte le rette del piano, la retta che meglio esprime il legame tra Y e X .

Il criterio più noto e maggiormente utilizzato per determinare i coefficienti di regressione " w " e " b ", consiste nella minimizzazione della somma dei quadrati degli errori, espressi dalla seguente funzione *Sum of Squared Errors* (**SSE**):

$$SSE = \sum_{i=1}^m e_i^2 = \sum_{i=1}^m [y_i - f(x_i)]^2 = \sum_{i=1}^m [y_i - wx_i - b]^2$$

Tale funzione è quadratica e convessa rispetto ai parametri del modello di regressione e ammette pertanto un unico punto di minimo che può essere ricavato imponendo che le sue derivate parziali, rispetto ai due parametri del modello di regressione, siano nulle.

Nel caso specifico, è sufficiente risolvere un sistema lineare di 2 equazioni in 2 incognite per ottenere i valori ottimali dei parametri del modello di regressione.

Rivolghiamo l'attenzione al caso generale in cui si considerino contemporaneamente " $n > 1$ " variabili esplicative.

In questo caso il legame probabilistico tra la variabile target " Y " e le " n " variabili esplicative " X^j " sarà

$$Y = w^1 X^1 + \dots + w^n X^n + b + \varepsilon$$

Tornando a considerare il dataset presentato in precedenza utilizziamo le seguenti variabili

- **IBMbase**
- **Appbase**


per prevedere il valore della variabile di risposta **Sales**, nel qual caso consideriamo il seguente modello

$$\text{Sales} = w^{\text{IBMbase}} \text{IBMbase} + w^{\text{AppBase}} \text{Appbase} + b + \varepsilon$$

Regressione Lineare Multipla

8

Regression Model [Sales = 2.19 + 0.15 * IBMbase + 0.19 * AppBase] - $R^2 = 0.8834$ - p-value = 0.0000



È importante sottolineare come il modello di regressione lineare multipla possa essere generalizzato in modo tale da prendere in considerazione non solo la comparsa dei termini singoli ma anche il loro elevamento a potenza e i termini rettangolari o termini di interazione aventi ordine superiore.

In questo caso il legame probabilistico tra la variabile target "**Y**" e le "**n**" variabili esplicative "**X_j**" sarà descritto in forma generale come segue:


$$Y = w^1 X^1 + \dots + w^n X^n + w^{n+1} (X^1)^2 + w^{n+2} X^1 X^2 + \dots + w^l (X^n)^2 + b + \varepsilon$$

In questo caso il numero di parametri del modello, parametri da stimare tramite la minimizzazione della funzione SSE, sarà pari a "**l+1**" e di norma si parlerà di "**l+1**" *gradi di libertà* del modello di regressione considerato.

Regressione Lineare Multipla

10

Regression Model [Weight = -593.89 + 208.29*GasTankSize + 10.15*Horsepower + -2.71*GasTankSize*GasTankSize + -0.02*Horsepower*Horsepower] - $R^2 = 0.7764$ - p-value = 0.0000



Assunzioni relative ai residui

La variabile casuale “ ε ” che rappresenta gli errori, comparando nei modelli di regressione che abbiamo esposto in precedenza, deve soddisfare alcune ipotesi.

La variabile “ ε ” deve essere assimilabile a *rumore casuale*, privo di effetti osservabili sulla variabile di risposta “ Y ”. Di norma si pensa a “ ε ” come al risultato dell’effetto di differenti variabili indipendenti, escluse dal modello di regressione, ognuna delle quali contribuisce un effetto trascurabile sui valori assunti dall’attributo target “ Y ”.

Se la determinazione dei coefficienti di regressione avviene minimizzando la funzione SSE, la variabile aleatoria “ ε ” deve essere distribuita secondo una *distribuzione normale* con media nulla e deviazione standard “ σ ”. Questa assunzione si traduce nella seguente *prima ipotesi*:

$$E(\varepsilon_i | x_i) = 0 \quad \text{Var}(\varepsilon_i | x_i) = \sigma^2$$

La *seconda ipotesi*, consiste nel richiedere che i *residui* " ε_i " e " ε_k ", corrispondenti a due distinte osservazioni " x_i " e " x_k ", siano *indipendenti* per qualunque scelta di " i " e " k ".

Infine, la *terza ipotesi* consiste nel richiedere che la *deviazione standard* (varianza), *dei residui sia costante*, al variare dei valori delle singole componenti delle osservazioni. In questo caso si parla di *omoschedasticità* (eteroschedasticità nel caso contrario).

Segnaliamo inoltre, che il modello di regressione è tanto più accurato quanto più la deviazione standard dei residui (standardizzati) è prossima a zero. Di norma viene computato lo stimatore della deviazione standard che viene nominato come *errore standard* della stima e svolge un ruolo molto importante nel determinare l'accuratezza di un modello di regressione, in quanto il suo valore determina l'entità dell'incertezza (dispersione) rispetto al valore predetto.

L'impostazione e lo sviluppo di un modello di regressione lineare possono apparire semplici, dal momento che anche i più diffusi fogli di calcolo consentono di determinare i coefficienti.

La facilità di elaborazione può tuttavia alimentare false certezze circa la reale significatività del modello di stima ricavato.





Esistono diversi aspetti, che prenderemo in considerazione per valutare la qualità e l'accuratezza predittiva di un modello di regressione lineare:

- *Normalità ed indipendenza dei residui*
- *Significatività dei coefficienti*
- *Analisi della varianza*
- *Coefficiente di determinazione*
- *Coefficiente di correlazione lineare*
- *Multi-collinearità delle variabili esplicative*
- *Limiti di confidenza della predizione.*

Valutazione dei Modelli

Normalità e indipendenza dei residui

Per verificare se la distribuzione dei residui è normale abbiamo a disposizione *rappresentazioni grafiche* e *test di ipotesi*.



I *test di ipotesi* utilizzabili sono i seguenti:

- *Kolmogorov-Smirnoff*
- *Shapiro-Wilk*
- *Lilliefor*

I risultati dei test di ipotesi devono essere letti alla luce di quanto emerge dall'analisi dei grafici.

Kolmogorov-Smirnoff normality test on residuals REJECTED at the 0.05 level

Lilliefor normality test on residuals REJECTED at the 0.05 level

Kolmogorov-Smirnoff normality test on residuals REJECTED at the 0.01 level

Lilliefor normality test on residuals REJECTED at the 0.01 level

Per verificare se i *residui* " ε_i " e " ε_k " sono *indipendenti* per qualunque scelta di " i " e " k " abbiamo a disposizione un opportuno test di ipotesi.





Si tratta del *test di Durbin-Watson* che applicato ai residui del modello di regressione relativo a **Sales** porta a rifiutare l'ipotesi di indipendenza dei residui, ovvero si ottiene un *p-value* pari a 0.0039.

L'*omoschedasticità* dei residui può essere valutata in termini grafici.


Inoltre, è possibile valutare l'influenza di ogni osservazione sul modello di regressione che è stato sviluppato; questa influenza è misurata dalla *distanza di Cook* che normalmente viene indicata come " D_i " per ogni residuo " i ".

Di norma valori della distanza di Cook maggiori dell'unità portano a considerare l'osservazione corrispondente come *osservazione influente* e quindi da analizzare con particolare attenzione a fini di validazione del modello di regressione lineare considerato.


Regression Model [Sales = -10.89 + 0.85*Titles] - $R^2 = 0.9007$ - p-value = 0.0000



L'*omoschedasticità* dei residui può essere valutata in termini grafici.



La mancanza di omoschedasticità compromette il valore del modello di regressione e deve essere assolutamente corretta, usualmente ricorrendo ad opportune *trasformazioni dei dati* (trasformazione logaritmica applicata ad entrambi gli assi).



Significatività dei coefficienti

I valori

$$\hat{w}$$

ricavati tramite la minimizzazione della SSE, non sono i veri valori dei coefficienti di regressione

$$w = (w^1, \dots, w^{l+1})$$

che compaiono nel modello probabilistico,

$$Y = f(X^1, \dots, X^n) = w^1 X^1 + \dots + w^n X^n + w^{n+1} (X^1)^2 + w^{n+2} X^1 X^2 + \dots + w^l (X^n)^2 + b + \varepsilon$$

ma ne rappresentano una stima.

Si tratta di un problema di statistica inferenziale in cui i coefficienti di regressione rappresentano i parametri incogniti della popolazione, le “m” osservazioni costituiscono un campione estratto dalla popolazione e i coefficienti che minimizzano SSE sono stimatori puntuali ai quali viene di norma associato un intervallo di confidenza.

È possibile valutare l'importanza di ogni variabile esplicativa, per prevedere il valore della variabile di risposta, valutando l'intervallo di confidenza del corrispondente coefficiente di regressione.

Se l'intervallo di confidenza contiene il valore nullo non c'è ragione di pensare che la corrispondente variabile esplicativa sia effettivamente tale nei confronti della variabile di risposta del modello di regressione lineare.

```
-----  
Coefficients C.I. at 0.90 confidence level  
-----
```

```
      intercept =    4.154318 [ -0.170000,    8.478636]  
      Weight    =    0.003694 [  0.002281,    0.005108]  
      Horsepower =   -0.008614 [ -0.047757,    0.030529]  
Weight*Horsepower =    0.000006 [ -0.000006,    0.000017]  
-----
```

```
-----  
Coefficients C.I. at 0.95 confidence level  
-----
```

```
      intercept =    4.154318 [ -1.011619,    9.320256]  
      Weight    =    0.003694 [  0.002005,    0.005383]  
      Horsepower =   -0.008614 [ -0.055375,    0.038147]  
Weight*Horsepower =    0.000006 [ -0.000008,    0.000019]  
-----
```

Valutazione dei Modelli

È possibile valutare l'importanza di ogni variabile esplicativa, per prevedere il valore della variabile di risposta, valutando l'intervallo di confidenza del corrispondente coefficiente di regressione.

Se l'intervallo di confidenza contiene il valore nullo non c'è ragione di pensare che la corrispondente variabile esplicativa sia effettivamente tale nei confronti della variabile di risposta del modello di regressione lineare.

statistica associata al test di ipotesi

*probabilità di ottenere un t-value
maggiore per puro caso*

significatività del termine

Regression Model Summary

GasTankSize = a0 + a1*Weight + a2*Horsepower + a3*Weight*Horsepower

Termine	Stima	Errore Std	t-value	Pr > t
a0	4.154318	2.607253	1.5934	0.1139
a1	0.003694	0.000852	4.3343	0.0000
a2	-0.008614	0.023600	-0.3650	0.7158
a3	0.000006	0.000007	0.8268	0.4101

Analisi della varianza

L'analisi della varianza (**ANOVA**, **AN**alysis **OF** **VA**riance) rappresenta uno strumento per valutare il legame che esiste tra la variabile di risposta e variabili esplicative categoriche.

Le informazioni che caratterizzano l'**ANOVA** sono le seguenti:

Sum Sq.

sum of squares $RSS_{reg} = \sum_{i=1}^m (\hat{y}_i - \bar{y})^2$ $RSS_{tot} = \sum_{i=1}^m (y_i - \bar{y})^2$

d.f.

degrees of freedom per la componente considerata

Mean Sq.

$\frac{RSS}{d.f.}$

F

valore della statistica

$$F = \frac{\frac{RSS}{d.f.}}{\frac{\sum_{i=1}^m (\hat{y}_i - y_i)^2}{d.f. err}}$$

Prob>F

probabilità di ottenere un valore più grande di F per puro caso

L'analisi della varianza per il modello di regressione appena analizzato porta ad ottenere:

Regression ANOVA					

Source	Sum Sq.	d.f.	Mean Sq.	F	Prob>F
Model	791.67	3.00	263.89	99.81	0.00
Resid	296.13	112.00	2.64		
Total	1087.79	115.00			

Nel caso in cui si consideri l'**ANOVA** della variabile di risposta **Gas Tank Size** rispetto alle variabili esplicative **Type** e **Country** otterremo quanto segue:

Analysis of Variance					
Source	Sum Sq.	d.f.	Mean Sq.	F	Prob>F
Country	0.87	2	0.4374	0.11	0.9
Type	331.51	4	82.8779	19.98	0
Country*Type	100.62	8	12.5779	3.03	0.0043
Error	418.93	101	4.1478		
Total	1087.79	115			

Constrained (Type III) sums of squares.

Nel caso in esame è possibile concludere che la variabile **Type** porta ad avere valori medi differenti della variabile target **Gas Tank Size**, mentre la variabile **Country** sembra non portare a valori medi differenti della variabile target.

Coefficiente di determinazione

Il *coefficiente di determinazione*, denominato anche **R^2 multiplo**, rappresenta la percentuale di varianza totale spiegata da parte delle variabili predittive, e quindi da parte del modello.

$$R^2 = \frac{RSS_{reg}}{RSS_{tot}} = \frac{\sum_{i=1}^m (\hat{y}_i - \bar{y}_i)^2}{\sum_{i=1}^m (y_i - \bar{y}_i)^2} = 1 - \frac{\sum_{i=1}^m (\hat{y}_i - y_i)^2}{\sum_{i=1}^m (y_i - \bar{y}_i)^2} = 1 - \frac{RSS_{err}}{RSS_{tot}}$$

Assume valori compresi nell'intervallo $[0,1]$ e nel caso in cui per un modello il valore assunto sia molto prossimo ad uno allora il modello di regressione spiega una larga parte della variazione della variabile target (Y).

Il coefficiente di determinazione tende a crescere all'aumentare del numero di variabili incluse nel modello di regressione lineare (*numero di parametri associati al modello di regressione ovvero gradi di libertà " $l+1$ "*) e a sovrastimare la percentuale di varianza spiegata dal modello.

Per evitare questo inconveniente viene normalmente utilizzato un'altro indicatore, noto con il termine di **R^2 adjusted**, definito come segue:

$$R^2_{adjusted} = 1 - (1 - R^2) \frac{m - 1}{m - l - 1}$$

Nel caso del modello di regressione per la variabile target presentato in precedenza avremo:

$$R^2 = 0.72777$$

$$R^2_{adjusted} = 0.72048$$

Nel caso in esame non esiste una differenza rilevante tra i due coefficienti di determinazione in quanto il numero di gradi di libertà è pari a 4 mentre il numero di osservazioni appartenenti al dataset è uguale a 116 portando ad ottenere

$$\frac{116 - 1}{116 - 4} = 1.02678$$

Al contrario se considerassimo un *modello di regressione lineare* che include le seguenti variabili esplicative

- **Weight**
- **Horsepower**
- **Displacement**
- **Turning Circle**

insieme ai loro quadrati ed alle loro interazioni a coppie otterremo i seguenti valori dei coefficienti di determinazione:

$$R^2 = 0.80808$$

$$R^2_{adjusted} = 0.78148$$

In questo caso si inizia ad osservare uno scostamento dei due coefficienti, l'aumento della complessità del modello (gradi di libertà) potrebbe non essere giustificato dall'incremento del valore del coefficiente di determinazione.

Si osservi che nei modelli di regressione lineare semplice è possibile verificare come il coefficiente di determinazione coincida con il quadrato del coefficiente di correlazione lineare.

Nel caso in cui si consideri il modello di regressione lineare semplice avente come variabile target la variabile **Gas Tank Size** e come variabile esplicativa la variabile **Weight** otterremo quanto segue:

$$R^2 = 0.71707$$

$$\text{corr}(\text{Gas Tank Size}, \text{Weight}) = 0.8468$$

Multi-collinearità delle variabili indipendenti

In un modello di regressione lineare multipla si richiede che le variabili esplicative siano tra loro indipendenti.

Se si incontra una significativa correlazione lineare tra due o più variabili indipendenti allora si parla di *collinearità* o *multi-collinearità*.

In tali condizioni la stima dei coefficienti risulta inaccurata e compromette la significatività del modello di regressione.

È importante provvedere alla rimozione delle cause della collinearità per esempio selezionando solo alcune variabili esplicative o solo alcuni termini nei quali esse compaiono.

Una via per identificare se esiste multi-collinearità tra le variabili esplicative consiste nel procedere alla computazione della matrice di correlazione lineare tra le medesime e concludere che due di esse sono *collineari se il valore assoluto della correlazione è maggiore di una determinata soglia*.

Nel caso del modello di regressione quadratico per la previsione della variabile target “**Gas Tank Size**” otterremo la seguente matrice di correlazione

	Weight	Horsepower	Displacement	Turning Circle
Weight	1.0000	0.7067	0.8300	0.7518
Horsepower	0.7067	1.0000	0.7642	0.4825
Displacement	0.8300	0.7642	1.0000	0.7467
Turning Circle	0.7518	0.4825	0.7467	1.0000

Per evidenziare legami multivariati tra le variabili esplicative è possibile computare il *fattore di incremento della varianza* (*Variance Inflation Factor* **VIF**) definito per ogni variabile X_j come segue

$$VIF_j = \frac{1}{1 - R_j^2}$$

dove R_j^2 rappresenta il coefficiente di determinazione del modello di regressione lineare che ha come variabile di risposta la variabile X_j e come variabili esplicative le rimanenti variabili esplicative del modello di regressione originale.

Di norma valori di *VIF maggiori di 5* sono indicatori della presenza di *multi-collinearità* tra le variabili esplicative.

Una volta validato, il modello di regressione

$$Y = f(X^1, \dots, X^n)$$

può essere utilizzato per prevedere il valore atteso della variabile target Y in corrispondenza della realizzazione del vettore delle variabili esplicative $\underline{X}$


$$\underline{X} = (x^1, \dots, x^n)$$

Il modello di regressione non fornisce solo il valore atteso della variabile di risposta Y ma anche indicatori per valutare l'utilità del modello medesimo:

- *intervallo di predizione* contiene il valore atteso $E[Y]$
- *intervallo di confidenza* contiene il valore Y

in corrispondenza della realizzazione $\underline{x}$ del vettore delle variabili esplicative $\underline{X}$.

Nel caso del modello di regressione lineare relativo alla variabile target **Sales** che utilizza come variabile esplicativa la variabile **Titles** otteniamo il grafico riportato nella slide seguente.



Lo sviluppo di un modello di regressione lineare multipla richiede di selezionare tra tutte le variabili candidate un sottoinsieme delle medesime che risultino le più informative per spiegare l'andamento della variabile target.

La selezione delle variabili predittive è un'attività particolarmente complessa, soprattutto nel caso in cui il numero di variabili candidate ad essere impiegate come variabili esplicative sia molto elevato.

A tal fine sono state sviluppate *tecniche di selezione automatica delle variabili* che si suddividono in:

- *Forward inclusion*
- *Backward elimination*
- *Mixed*

Inclusion Forward

Si parte da una soluzione per la quale l'insieme delle variabili selezionate è vuoto. Si procede ad aggiungere una variabile all'insieme delle variabili selezionate, prelevandola dall'insieme delle variabili candidate ad essere variabili esplicative (senza ripetizione).

Tra tutte le variabili non ancora aggiunte all'insieme delle variabili selezionate viene inclusa quella variabile, appartenente all'insieme delle variabili candidate, cui compete il massimo incremento di valore predittivo nei confronti della variabile target.

Esistono differenti criteri per la scelta della variabile da includere, tra questi è possibile ricordare:

- *riduzione della somma dei quadrati dei residui*
- *incremento del coefficiente di regressione adjusted*
- *incremento del valore della statistica F*

Esclusione Backward

Si parte da una soluzione per la quale l'insieme delle variabili selezionate contiene tutte le variabili candidate ad essere variabili esplicative. Si procede ad eliminare una variabile dall'insieme delle variabili selezionate.

Tra tutte le variabili non ancora eliminate dall'insieme delle variabili selezionate viene eliminata quella variabile, cui compete la minima riduzione del valore predittivo nei confronti della variabile target.

Esistono differenti criteri per la scelta della variabile da escludere.

Se applichiamo la procedura *Forward Inclusion* al modello di regressione lineare avente come variabile target la variabile **Gas Tank Size** e come candidate variabili esplicative le seguenti variabili; **Weight**, **Horsepower**, **Turning Circle** e **Displacement** con i seguenti parametri:

- *Prob to enter* = 0.025
- *Maxiterations* = 100

otteniamo

Initial columns included: none

Step 1, added column 1, $p=4.89546e-033$

Final columns included: 1

'Coeff'	'Std.Err.'	'Status'	'p'
[0.0049]	[2.8604e-004]	'In'	[4.8955e-033]
[0.0104]	[0.0054]	'Out'	[0.0558]
[-0.0418]	[0.0744]	'Out'	[0.5758]
[0.0026]	[0.0046]	'Out'	[0.5650]

Se applichiamo la procedura *Backward Elimination* allo stesso modello di regressione lineare con i medesimi valori dei parametri, otteniamo

Initial columns included: 1 2 3 4

Step 1, removed column 4, $p=0.860955$

Step 2, removed column 3, $p=0.713442$

Step 3, removed column 2, $p=0.0558067$

Final columns included: 1

'Coeff'	'Std.Err.'	'Status'	'P'
[0.0049]	[2.8604e-004]	'In'	[4.8955e-033]
[0.0104]	[0.0054]	'Out'	[0.0558]
[-0.0418]	[0.0744]	'Out'	[0.5758]
[0.0026]	[0.0046]	'Out'	[0.5650]

Interessante, entrambe le procedure di *Stepwise Selection* portano ad includere solo la prima variabile nel modello di regressione, valutando che solo **Weight** è informativa per prevedere il valore della variabile target **Gas Tank Size**.